

tempssm 詳細マニュアル

Version 0.3.0

平尾章・馬場真哉・市野川桃子

2026-07-31

概要

tempssm は、気温や水温など、環境中で観測される温度時系列データに対して状態空間モデルを適用するための R パッケージです。長期トレンド、季節変動、自己回帰的依存性、および任意の外生効果が、観測された温度の時間変動にどのように寄与しているかを評価するための実用的な枠組みを提供します。計算バックエンドとして KFAS R パッケージ (Helske, 2017) を用い、カルマンフィルタリングおよび平滑化によって推定される線形ガウス状態空間モデルを適用します。

主な特徴

- 環境中で観測される温度時系列データに線形ガウス状態空間モデルを適用
- 温度の動態を解釈しやすい潜在成分として表現：長期トレンド、季節変動、自己回帰構造、および任意の外生効果
- 任意の季節周期に対応（ただし実例と検証では、主として月別の温度データを対象）
- 自己回帰成分の次数をユーザーが指定可能（デフォルト：AR(1)）
- モデル評価のための時系列交差検証ツールを提供

入力データ形式

R の `ts` オブジェクトが、tempssm の主要な入力データ形式です。tempssm() に渡す温度時系列データは、単変量の `ts` オブジェクトとして与えます。任意で指定する外生変数は、単変量または多変量の `ts` オブジェクトとして与えることができます。`ts` クラスは、等間隔の時系列を扱うための base R の標準的な形式です（R 公式の `stats::ts` ドキュメントを参照：<https://search.r-project.org/R/refmans/stats/html/ts.html>）。本パッケージには、表形式データや観測データをモデル適用前に `ts` オブジェクトへ変換するためのユーティリティ関数も含まれています。

tempssm() が用いる季節周期は、入力された `ts` オブジェクトの `frequency` 属性から決まります。たとえば、月別データでは `frequency = 12` を用います。

既存研究と本パッケージの範囲

tempssm は、線形ガウス状態空間モデルを用いて温度時系列を解析するための、対象分野に特化したワークフローを提供します。温度データへの応用に合わせた単一の R パッケージインターフェースの中に、モデル構築、成分抽出、不確実性の要約、残差診断、可視化、時系列交差検証を統合しています。

本パッケージは、線形ガウス状態空間モデリング、カルマンフィルタリング、カルマン平滑化を含む、確立された統計的方法論に基づいています。モデル推定は、R における状態空間モデルの汎用的な枠組みを提供する KFAS パッケージを通じて行われます。

初期実装は、線形ガウス状態空間モデルを用いて海水温トレンドを解析した馬場ら (2024) に付随する補足コードに基づいています。この補足コードは以下で公開されています。

<https://github.com/logics-of-blue/sea-temperature-trend-jogashima>

この先行実装と比べて、`tempssm` は、入力検証、文書化された S3 メソッド、テスト、診断、交差検証ユーティリティ、およびより広範な温度時系列解析のための例を備えた、再利用可能な R パッケージインターフェースへとワークフローを拡張しています。

モデル概要

`tempssm` で用いるモデルは、基本構造時系列モデル (Basic Structural Time Series Model; BSTSM) を拡張したものと位置づけられます。BSTSM は、観測時系列を潜在的なトレンド成分、季節成分、不規則成分から構成されるものとして表す状態空間モデルの標準的な定式化の一つです。馬場ら (2024) による温度時系列への適用を踏まえ、`tempssm` では、BSTSM に自己回帰的依存性と任意の外生効果を加えています。これにより長期的な温度変化、季節周期、短期的な変動を分けて検討しやすくしています。

計算バックエンドには KFAS を使い、推定済みの `tempssm` オブジェクトにはフィルタリング推定値と平滑化推定値の両方が格納されます。特に断らない限り、本マニュアルでは、要約統計、診断、プロットの解釈は平滑化推定値に基づいています。

数式を含む詳細なモデル定式化は、`vignette model-specification` を参照してください。観測方程式、状態方程式、季節成分の制約、自己回帰成分、外生成分、推定パラメータ数、推定手順の詳細を説明しています。PDF 版はこちらから入手できます。

<https://github.com/akihirao/tempssm/blob/main/vignettes/model-specification.pdf>

チュートリアルの流れ

このチュートリアルでは、`tempssm` を月別の環境温度時系列へ適用する 典型的なワークフローを示します。演習 I では、シミュレーションで生成された 海面水温 (SST) データセット `sst_sim` を用いて、外生変数を含まないベースラインの状態空間モデルを当てはめ、潜在成分の可視化、残差診断、短期予測を行います。演習 II では、同じ流れを外生変数ありモデルへ拡張し、シミュレーションで生成された海洋環境変数を追加することで、モデル解釈と条件付き予測性能がどのように変わるかを、残差診断と時系列交差検証に基づいて確認します。

ここでの目的は、シミュレーションデータから新しい科学的結論を導くことではありません。モデルの当てはめ、診断、予測、モデル比較の流れを、再現可能な例として示すことを目的としています。

セットアップ

以下の例を実行するため、以下の R パッケージを読み込みます。未インストールのパッケージがあれば、適宜、インストールください。

```
## Set libraries
library(tempssm)
library(forecast)

library(purrr)
library(tibble)
library(readr)
library(dplyr)
library(ggplot2)

library(patchwork)
```

演習 I: 単変量温度時系列のベースラインモデル

演習 I では、外生変数を含まない単変量モデルについて、モデル適用、潜在成分の可視化、残差診断、および短期予測の基本的なワークフローを示します。

シミュレーション SST データセットの読み込み

パッケージには、シミュレーションで生成された月別海面水温（SST）データセット `sst_sim` が含まれています。

- データセット: 城ヶ島地先（神奈川県三浦市）のシミュレーション月別 SST
- 単位: °C
- 期間: 1998 年 1 月から 2023 年 2 月

このデータセットは、馬場ら (2024) で報告された城ヶ島地先の海水温に対する状態空間モデル解析に基づいて生成されたものです。ここでは、`tempssm` の基本的なワークフローを示すための再現可能な応答時系列として使用します。演習 II では、この同じシミュレーション SST に、シミュレーションで生成された海洋環境変数を組み合わせます。

```
data(sst_sim) # load a ts object of SST off Jogashima
head(sst_sim)
```

```
##           Jan   Feb   Mar   Apr   May   Jun
## 1998 16.19 13.82 16.44 16.49 19.70 21.83
```

```
summary(sst_sim)
```


```
##           Temp
## Min.      :11.17
## 1st Qu.:16.22
## Median :18.39
## Mean     :18.23
## 3rd Qu.:20.11
## Max.     :26.10
```

月別 SST 時系列のプロット

まず、月別 SST 時系列を可視化し、見かけのトレンド、季節変動、欠測値の有無を含む全体的な構造を確認しておきます。

```
plt_sst_sim <- forecast::autoplot(sst_sim) +
  labs(y = expression(Temp.~(degree*C)),
       x = "Time (year)") +
  ggtitle("Monthly SST off Jogashima, Japan") +
  theme_classic()

plot(plt_sst_sim)
```



SST の全体平均は約 18.2 °C であり、明瞭な季節変動パターンが認められます。生の時系列からは、記録の開始期から 2008 年前後にかけて SST が低下し、その後に上昇するようにも見えます。ただし、年変動も認められるため、生の時系列だけから長期パターンを評価することは容易ではありません。

線形ガウス状態空間モデルの適用

本パッケージのコア関数 `tempssm()` に温度時系列データの `ts` オブジェクト（ここでは `sst_sim`）を与えて、実行すると、モデル構築からパラメータ推定までが一挙に処理されます。返り値として、フィルタリング推定値、平滑化推定値などの結果に加えて、構築されたモデルや入力データなどが S3 クラスの `tempssm` オブジェクト（ここでは `res_ar1`）に格納されます。デフォルトでは `tempssm()` は 1 次の自己相関回帰モデルをあてはめます。

```
# model with first-order autoregressive component
res_ar1 <- tempssm(sst_sim) # (ar_order=1: default)
summary(res_ar1)
```

```
## tempssm summary
## -----
## Call:
## tempssm(temp_data = sst_sim)
##
## Model fit:
## Likelihood type: marginal
## Log-likelihood : -198.19
## k : 5
## Diffuse states : 13
## Converged : TRUE
##
```

```
## Variance parameters:
##   Observation (H): 0.07496416
##   State (Q trend): 4.937122e-06
##   State (Q season): 0.0001763538
##   State (Q ar): 0.1202156
##
## Components of auto-regression:
##   Order of AR: 1
##   Coefficient of AR1: 0.7579372
```

結果の要約から、モデルが収束したこと (Converged: TRUE) を確かめます。その他に統計量として、パラメーター数 (k)、対数尤度 (Log-likelihood)、尤度タイプ、散漫初期化された状態数が示されています。パラメーター推定値は、推定された状態空間モデルにおける誤差分散と自己回帰係数に対応します。H は観測誤差分散であり、潜在状態では説明されない観測温度系列の変動を表します。Q 系の項は各潜在成分の 過程誤差分散です。Q trend は長期トレンド成分、Q season は季節成分、自己回帰成分の過程誤差分散は短期的な自己回帰成分の変動を表します。AR1 は、その短期成分における 1 次自己回帰依存性を表します。

対数尤度と対応する推定パラメーター数は、logLik() を用いて推定済みの tempssm オブジェクトから直接取得できます。

```
ll <- logLik(res_ar1)
ll
```

```
## 'log Lik.' -198.1929 (df=5)
```

```
attr(,"df") # number of parameters
```

```
## [1] 5
```


tempssm() は、デフォルトでは KFAS の周辺尤度 (marginal likelihood) を用いてパラメーター推定をおこないます。一方で、marginal = FALSE を明示すれば、散漫尤度 (diffuse likelihood) も利用できます。選択された尤度タイプは推定済みの tempssm オブジェクトに保存され、logLik() や summary() などの下流メソッドでも一貫して用いられます。

本パッケージでは、tempssm オブジェクトに対する AIC は自動計算しません。これは、状態空間モデルにおける AIC 比較では、尤度タイプ、散漫初期化、潜在状態構造の違いなどに応じて解釈に注意が必要となる場合があるためです。AIC をデフォルトのモデル選択基準として提示することを避けるため、tempssm では AIC に基づく自動比較は提供していません。その代わり、本マニュアルでは、残差診断と時系列クロスバリデーションを組み合わせたモデル評価の流れを重視します。なお、独自のモデル評価ワークフローで必要となる場合に備えて、対数尤度と推定パラメーター数は logLik() から 取得できます。

潜在成分のプロット

成分プロットでは、推定された長期水準、ドリフト、季節変動、自己回帰的依存性を可視化します。

```
# plot all components at once
plot(res_ar1)
```



```
## [1] 0.08777084
```

パネル左上の長期トレンドは、解析期間の前半に SST が低下し、2008 年前後以降に上昇するパターンを示しています。この例では、解析期間全体を通した SST の平均的な年変化率は約 0.088 °C です。

ただし、この全期間平均は、時間とともに変化するドリフト成分とあわせて解釈する必要があります。パネル右上では、ドリフトが 2008 年前後までは負で、その後に正へ転じており、長期的な SST パターンが低下から上昇へ移行したことに対応しています。灰色の網掛け部分は、推定された潜在状態の 95% 信頼区間を表します。


スクリプト内で明示的な関数名を使いたい場合は、`plot_tempssm_components()` から同じ成分プロットを `ggplot` オブジェクトとして取得できます。個別の成分についてプロットを取得するには、`component` 引数を指定します。

```
# extract individual component plots
plt_level <- plot_tempssm_components(res_ar1, component = c("level"))
plt_drift <- plot_tempssm_components(res_ar1, component = c("drift"))
plt_season <- plot_tempssm_components(res_ar1, component = c("season"))
plt_ar <- plot_tempssm_components(res_ar1, component = c("ar"))
```

モデル診断

本パッケージでは、推定モデルの残差に注目して、モデルが十分に時系列構造を捉えているかを確認するための診断用関数を提供しています。具体的には、残差の時系列プロット、自己相関、分布、および Ljung-Box 検定を用いて、残存する時間依存性や正規誤差仮定からの大きな逸脱がないかを確認できます。

```
resid <- get_tempssm_residuais(res_ar1)
plot_tempssm_residuais(resid)
```



ここでは、`get_tempssm_residuals()` によって標準化再帰残差を取り出し、`plot_tempssm_residuals()` によって残差時系列プロット、ACF プロット、ヒストグラムを確認します。3つの図は、それぞれ上段、下段左、下段右に表示されます。これらの図を用いて、残差に留意すべきパターンが残っていないかを確認します。

本マニュアルでは、残差診断の標準的な流れとして、まず残差を時間軸を保持した `ts` オブジェクトとして取り出し、その残差オブジェクトを診断用関数に明示的に渡す方法を用います。この流れにより、どの時点の残差が診断に含まれているか、また利用できない残差があるかどうかを確認しやすくなります。

`get_tempssm_residuals()` は、デフォルトでは入力時系列の時間軸を保持した `ts` オブジェクトとして残差を返します。欠損値または非有限の残差は `NA` として保持されます。完全な数値ベクトルを必要とする計算では、`get_tempssm_residuals(res, keep_time = FALSE)` を用います。

標準化再帰残差を時間軸を保持した `ts` オブジェクトとして取り出すと、初期の一部の残差が `NA` として返される場合があります。散漫初期化を用いる状態空間モデルでは、散漫期間中に標準化再帰残差が通常の意味で定義されないことがあります。そのため、これらの `NA` は、その時点でモデル推定が失敗したことを直ちに意味するものではありません。むしろ、散漫成分が解消されるまで、比較可能な標準化再帰残差が得られないことを示しています。

標準化再帰残差の `NA` は、その観測値が対数尤度の計算から除外されたことを意味するものではありません。対数尤度は、KFAS によるカルマンフィルタの尤度計算に基づき、選択された尤度タイプに応じて散漫初期化を考慮して計算されます。一方で、標準化再帰残差は診断用の量であり、散漫期間中には通常の意味で利用できない場合があります。そのため、尤度に基づくモデル推定と残差診断は関連していますが、同一の対象を同じ形で扱っているわけではありません。

この点は残差診断の解釈に重要です。ACF プロットや Ljung-Box 診断は、有限の標準化再帰残差が得られている期間に対する診断として解釈する必要があります。`get_tempssm_residuals()` によって時間軸を保持した残差を確認することで、元の時系列のどの期間が残差診断に含まれているかを把握できます。

この例では、残差 ACF プロットにおいて、連続する複数のラグにわたる有意な自己相関や、季節周期に対応する反復的なパターンは明瞭ではありません。多数のラグを確認する場合には、単発の突出が偶然に生じるこ

ともあるため、ACF プロットだけでモデル変更を判断するのではなく、Ljung-Box 検定や残差時系列プロットとあわせて解釈します。

取り出した残差系列の可視化には `plot_tempssm_residuals(resid)` を用います。この関数により、残差時系列プロット、ACF プロット、残差の頻度分布を確認できます。Ljung-Box 診断と残差尖度をコンパクトな表として確認するには、`diagnose_residual_ts(resid)` を用います。検定に用いるラグは、デフォルトでは入力データの季節周期に合わせており、月別データでは lag 12 を用います。

```
diag <- diagnose_residual_ts(resid)
print(diag)
```

```
## # A tibble: 1 x 8
##   lb_stat lb_lag lb_df lb_pvalue kurtosis      n n_missing n_finite
##   <dbl>  <int> <int>    <dbl>    <dbl> <int>    <int>    <int>
## 1    9.68    12    12     0.644     3.26   302        13      289
```

`diagnose_residual_ts()` の返り値のうち、`lb_stat`、`lb_lag`、`lb_pvalue` はそれぞれ Ljung-Box 検定統計量、検定に用いたラグ、対応する P 値を表します。月別時系列では、デフォルトで季節周期に対応する lag 12 が用いられます。この例では、lag 12 までの残差自己相関に有意性は認められませんでした。

より長いラグにおける残差自己相関が気になる場合には、検定に用いるラグを手動で指定できます。例えば、次のコードでは lag 24 および lag 36 までの Ljung-Box 検定を追加で実行します。

```
diag_lag24 <- diagnose_residual_ts(resid, lb_lag = 24)
diag_lag36 <- diagnose_residual_ts(resid, lb_lag = 36)

diag_lags <- rbind(diag, diag_lag24, diag_lag36)
diag_lags$check <- c("lag 12", "lag 24", "lag 36")
diag_lags[, c("check", "lb_stat", "lb_lag", "lb_pvalue", "kurtosis")]
```

```
## # A tibble: 3 x 5
##   check lb_stat lb_lag lb_pvalue kurtosis
##   <chr>  <dbl>  <int>    <dbl>    <dbl>
## 1 lag 12    9.68    12     0.644     3.26
## 2 lag 24   19.5     24     0.725     3.26
## 3 lag 36   27.9     36     0.831     3.26
```

この例では、lag 24 および lag 36 まで範囲を広げても、有意な残差自己相関は認められませんでした。これらの検定結果は、残差 ACF プロットとあわせて解釈します。多数のラグを確認する場合には、少数のラグが偶然に信頼限界を超えることもあります。一方で、周期的または連続的な突出がみられる場合には、時間構造が残っている可能性があります。

自己回帰 (AR) 次数の検討

本マニュアルでは、`tempssm()` のデフォルトである AR(1) を作業モデルとして用います。自己回帰成分は、潜在的な水準、ドリフト、季節成分では表現されない短期的な系列依存性を吸収するために組み込まれています。そのため、高い AR 次数を自動的な改善として扱うのではなく、残差診断により自己相関が残っていると考えられる場合に、AR 次数を増減させて検討する方針が適切です。

例えば、AR(1) モデルを当てはめた後に残差自己相関が残る場合には、AR(2) モデルを当てはめ、同じ残差診断を繰り返すことができます。

```
# Optional sensitivity check with a second-order autoregressive component
res_ar2 <- tempssm(sst_sim, ar_order = 2)
summary(res_ar2)
```


```
## tempssm summary
## -----
## Call:
```



```
## tempssm(temp_data = sst_sim, ar_order = 2)
##
## Model fit:
##   Likelihood type: marginal
##   Log-likelihood : -198.19
##   k               : 6
##   Diffuse states  : 13
##   Converged       : TRUE
##
## Variance parameters:
##   Observation (H): 0.05517452
##   State (Q trend): 4.945287e-06
##   State (Q season): 0.0001859987
##   State (Q ar): 0.149755
##
## Components of auto-regression:
##   Order of AR: 2
##   Coefficient of AR1: 0.6553237
##   Coefficient of AR2: 0.07430046
```

```
resid_ar2 <- get_tempssm_residuals(res_ar2)
plot_tempssm_residuals(resid_ar2)
```

Residuals



```
diag_lag12_ar2 <- diagnose_residual_ts(resid_ar2, lb_lag = 12)
diag_lag24_ar2 <- diagnose_residual_ts(resid_ar2, lb_lag = 24)
diag_lag36_ar2 <- diagnose_residual_ts(resid_ar2, lb_lag = 36)
diag_lags_ar2 <- rbind(diag_lag12_ar2, diag_lag24_ar2, diag_lag36_ar2)
diag_lags_ar2$check <- c("lag 12", "lag 24", "lag 36")
```

```
diag_lags_ar2[, c("check", "lb_stat", "lb_lag", "lb_pvalue", "kurtosis")]
```

```
## # A tibble: 3 x 5
##   check lb_stat lb_lag lb_pvalue kurtosis
##   <chr>   <dbl> <int>   <dbl>   <dbl>
## 1 lag 12    9.61    12     0.650    3.26
## 2 lag 24   19.4    24     0.729    3.26
## 3 lag 36   27.9    36     0.831    3.26
```

この例では、AR(2) モデルの診断結果は AR(1) モデルとよく似ているため、低次の AR(1) をベースラインの仕様として用います。

推定されたパラメータと潜在状態の成分

推定済みの `tempssm` オブジェクトには、KFAS から返された平滑化状態推定値が格納されています。`res_ar1$kfs$alphahat` は、レベル、ドリフト、季節状態、自己回帰状態などの潜在状態推定値を含む行列です。この行列を確認すると、モデル内部で状態がどのように表現されているかを把握できます。

```
# Smoothing estimates
```

```
alpha_hat <- res_ar1$kfs$alphahat
head(alpha_hat)
```

```
##           level      slope sea_dummy1 sea_dummy2 sea_dummy3 sea_dummy4
## Jan 1998 18.65840 -0.01905354 -2.0428374 -0.9196344  0.5642451  0.9553992
## Feb 1998 18.63934 -0.01906722 -5.0256252 -2.0428374 -0.9196344  0.5642451
## Mar 1998 18.62028 -0.01909100 -2.8244535 -5.0256252 -2.0428374 -0.9196344
## Apr 1998 18.60118 -0.01911003 -2.0508949 -2.8244535 -5.0256252 -2.0428374
## May 1998 18.58207 -0.01914415  0.2882283 -2.0508949 -2.8244535 -5.0256252
## Jun 1998 18.56293 -0.01918604  1.9925949  0.2882283 -2.0508949 -2.8244535
##           sea_dummy5 sea_dummy6 sea_dummy7 sea_dummy8 sea_dummy9 sea_dummy10
## Jan 1998  1.6282639  4.9410126  2.4937014  1.9925949  0.2882283 -2.0508949
## Feb 1998  0.9553992  1.6282639  4.9410126  2.4937014  1.9925949  0.2882283
## Mar 1998  0.5642451  0.9553992  1.6282639  4.9410126  2.4937014  1.9925949
## Apr 1998 -0.9196344  0.5642451  0.9553992  1.6282639  4.9410126  2.4937014
## May 1998 -2.0428374 -0.9196344  0.5642451  0.9553992  1.6282639  4.9410126
## Jun 1998 -5.0256252 -2.0428374 -0.9196344  0.5642451  0.9553992  1.6282639
##           sea_dummy11      arima1
## Jan 1998 -2.8244535 -0.2178662
## Feb 1998 -2.0508949  0.1519895
## Mar 1998  0.2882283  0.4187224
## Apr 1998  1.9925949  0.2408084
## May 1998  2.4937014  0.7185730
## Jun 1998  4.9410126  1.0167731
```

通常の利用では、個別の成分を元の時系列インデックスを持つ `ts` オブジェクトとして取り出すためのヘルパー関数を使うと便利です。レベル成分は推定された長期的な温度水準を表し、ドリフト成分はその年あたりの変化率を表します。

```
# Smoothing estimate of level component
```

```
level_ts <- get_level_ts(res_ar1)
```

```
# Smoothing estimate of drift component
```

```
drift_ts <- get_drift_ts(res_ar1)
```

```
# Average drift rate per year across the full period
```

```
mean_drift_year <- mean(drift_ts)
```

```
print(mean_drift_year)
```

```
## [1] 0.08777084
```

SST の平均的な年変化率は、全期間では 0.0878 °C と推定されました。ただし、推定されたドリフトは時期によって符号が変化するため、この値は一定の上昇率ではなく、全期間を要約したモデルベースの指標として解釈します。

短期予測

推定済みの `tempssm` オブジェクトは、`predict()` に渡すことで短期予測を取得できます。デフォルトでは、`predict(res)` は観測期間の終了直後の 1 時点先予測値を返します。この機能は、推定モデルが水準、季節成分、自己回帰成分をどのように外挿するかを可視化・点検する目的で有用です。

```
pred_1 <- predict(res_ar1)
pred_1
```

```
##           Mar
## 2023 18.33035
```

複数時点先の予測値を取得したい場合には、`n.ahead` 引数を指定します。

```
pred_12 <- predict(res_ar1, n.ahead = 12)
pred_12
```

```
##           Jan           Feb           Mar           Apr           May           Jun           Jul           Aug
## 2023                18.33035 18.96985 21.33710 23.08522 23.51856 26.03694
## 2024 19.09319 16.16926
##           Sep           Oct           Nov           Dec
## 2023 22.69098 22.00902 21.74806 20.19190
## 2024
```

予測に伴う不確実性は、`interval` 引数を指定することで取得できます。`interval = "confidence"` は予測平均に対する信頼区間を返します。すなわち、予測される平均的な応答値に関する不確実性を表す下限値と上限値が返されます。一方で、`interval = "prediction"` は将来観測値に対する予測区間を返します。これは、将来の観測値そのものに関する不確実性を表す下限値と上限値であり、観測誤差も含まれるため、通常は confidence interval よりも prediction interval の方が広がります。信頼水準は `level` 引数で指定でき、デフォルトは 0.95 です。

```
pred_12_pi <- predict(
  res_ar1,
  n.ahead = 12,
  interval = "prediction",
  level = 0.95
)
pred_12_pi
```

```
##           fit           lwr           upr
## Mar 2023 18.33035 17.35029 19.31042
## Apr 2023 18.96985 17.85360 20.08610
## May 2023 21.33710 20.13453 22.53967
## Jun 2023 23.08522 21.82425 24.34619
## Jul 2023 23.51856 22.21551 24.82161
## Aug 2023 26.03694 24.70183 27.37204
## Sep 2023 22.69098 21.33016 24.05179
## Oct 2023 22.00902 20.62664 23.39141
## Nov 2023 21.74806 20.34682 23.14929
```

```
## Dec 2023 20.19190 18.77359 21.61020
## Jan 2024 19.09319 17.65904 20.52734
## Feb 2024 16.16926 14.72135 17.61717
```

これらの予測値は、確定的な将来予測ではなく、モデルに基づく外挿として解釈してください。一般に、予測期間が長くなるほど不確実性は大きくなり、長期の予測はトレンド、季節性、自己回帰構造に関するモデル仮定の影響を受けやすくなります。

演習 II: 外生変数を含むモデル

ここでは、外生要因が温度変動に与える影響を検討するために、状態空間モデリングの枠組みを拡張します。具体的には、黒潮流路に関連するシミュレーション海洋環境変数を、演習 I で用いたシミュレーション SST の外生変数として利用します。

シミュレーション海洋環境変数の読み込み

本パッケージには、2つのシミュレーション外生変数データセットが含まれています。

- `kuroshio_a_sim`: 黒潮 A 型流路の月別バイナリ指標
- `distance_sim`: 黒潮流路の月別離岸距離指標
- 期間: 1998 年 1 月から 2023 年 2 月

いずれも `frequency = 12` の単変量 `ts` オブジェクトです。これらは 馬場ら (2024) で用いられた黒潮関連変数に基づいて生成された月別のシミュレーションデータです。元の研究で用いられた一部の変数はより細かい時間分解能を持っていましたが、本パッケージに含まれるシミュレーションデータは、`tempssm` の例で扱いやすいように月別時系列として表現されています。

```
data(kuroshio_a_sim)
data(distance_sim)

head(kuroshio_a_sim)
```

```
##      Jan Feb Mar Apr May Jun
## 1998   0   0   0   0   0   0
```

```
head(distance_sim)
```

```
##      Jan Feb Mar Apr May Jun
## 1998 116 148  49 131  45  40
```

```
summary(kuroshio_a_sim)
```

```
##      kuroshio_a
## Min.      :0.0000
## 1st Qu.:0.0000
## Median :0.0000
## Mean    :0.2483
## 3rd Qu.:0.0000
## Max.    :1.0000
```

```
summary(distance_sim)
```

```
##      distance
## Min.      : 10.00
## 1st Qu.: 26.00
## Median : 43.00
## Mean    : 55.65
## 3rd Qu.: 84.00
## Max.    :150.00
```

時系列の整合性の確認

外生変数を含む状態空間モデルでは、応答変数と外生変数が共通し、整合した時間インデックスを持つ必要があります。この例では、`sst_sim`、`kuroshio_a_sim`、`distance_sim` は、同じ月別期間と同じ frequency を持っています。

```
series_info <- tibble::tibble(
  series = c("sst_sim", "kuroshio_a_sim", "distance_sim"),
  start = c(
    paste(start(sst_sim), collapse = "-"),
    paste(start(kuroshio_a_sim), collapse = "-"),
    paste(start(distance_sim), collapse = "-")
  ),
  end = c(
    paste(end(sst_sim), collapse = "-"),
    paste(end(kuroshio_a_sim), collapse = "-"),
    paste(end(distance_sim), collapse = "-")
  ),
  frequency = c(
    frequency(sst_sim),
    frequency(kuroshio_a_sim),
    frequency(distance_sim)
  ),
  missing = c(
    sum(is.na(sst_sim)),
    sum(is.na(kuroshio_a_sim)),
    sum(is.na(distance_sim))
  )
)

series_info
```

```
## # A tibble: 3 x 5
##   series      start end   frequency missing
##   <chr>      <chr> <chr>      <dbl>    <int>
## 1 sst_sim    1998-1 2023-2      12        0
## 2 kuroshio_a_sim 1998-1 2023-2      12        0
## 3 distance_sim 1998-1 2023-2      12        0
```

ユーザー自身の時系列データで開始時点や終了時点が異なる場合には、`trim_ts_overlap()` を用いて、応答系列と外生変数系列を共通の重複期間に切り出してからモデルを当てはめることができます。

応答変数と外生変数のプロット


シミュレーション SST と 2 つの黒潮関連変数をあわせて可視化し、データセット全体の構造を確認します。

```
plt_sst_exo <- forecast::autoplot(sst_sim) +
  labs(y = expression(Temp.~(degree*C)), x = "Time (year)") +
  ggtitle("Simulated monthly SST") +
  theme_classic()

plt_kuroshio_a <- forecast::autoplot(kuroshio_a_sim) +
  labs(x = "Time (year)", y = "A-type indicator") +
  ggtitle("Simulated Kuroshio A-type path") +
  scale_y_continuous(breaks = c(0, 1)) +
  theme_classic()
```

```
plt_distance <- forecast::autoplot(distance_sim) +
  labs(x = "Time (year)", y = "Offshore distance") +
  ggtitle("Simulated Kuroshio offshore distance") +
  theme_classic()

plt_sst_exo + plt_kuroshio_a + plt_distance +
  patchwork::plot_layout(ncol = 1)
```



ここで用いるシミュレーション外生変数には欠測値は含まれていません。ユーザー自身の外生変数データを用いる場合、欠測値はモデル当てはめの前に補完する、欠測期間を除外する、または解析期間を調整するなどして、外生変数に NA が残らない形に整えてください。tempssm() は外生変数の欠測値を許容しません。一方で、従属変数である温度時系列の欠測値は、カルマンフィルタリングおよび平滑化において未観測応答として扱われます。

ベースラインモデルの再利用

演習 II では演習 I と同じ応答系列を用いるため、外生変数なしの参照モデルとして、既に当てはめた AR(1) モデルを再利用します。

```
res_without <- res_ar1
summary(res_without)

## tempssm summary
## -----
## Call:
## tempssm(temp_data = sst_sim)
##
## Model fit:
```

```
## Likelihood type: marginal
## Log-likelihood : -198.19
## k : 5
## Diffuse states : 13
## Converged : TRUE
##
## Variance parameters:
## Observation (H): 0.07496416
## State (Q trend): 4.937122e-06
## State (Q season): 0.0001763538
## State (Q ar): 0.1202156
##
## Components of auto-regression:
## Order of AR: 1
## Coefficient of AR1: 0.7579372
```

これにより、比較の焦点をシミュレーション黒潮変数によって追加される情報に絞ることができます。

外生変数の結合

`tempssm()` の `exo_data` 引数には、単変量 `ts` オブジェクトまたは 多変量 `ts` オブジェクトを与えることができます。この演習では2つの外生変数を用いるため、`kuroshio_a_sim` と `distance_sim` を1つの多変量 `ts` オブジェクトに結合します。

```
exo_kuroshio <- cbind(kuroshio_a_sim, distance_sim)
colnames(exo_kuroshio) <- c("kuroshio_a", "distance")
```

```
head(exo_kuroshio)
```

```
##          kuroshio_a distance
## Jan 1998           0      116
## Feb 1998           0      148
## Mar 1998           0       49
## Apr 1998           0      131
## May 1998           0       45
## Jun 1998           0       40
```

```
start(exo_kuroshio)
```

```
## [1] 1998    1
```

```
end(exo_kuroshio)
```

```
## [1] 2023    2
```

```
frequency(exo_kuroshio)
```

```
## [1] 12
```

```
colnames(exo_kuroshio)
```

```
## [1] "kuroshio_a" "distance"
```

```
sum(is.na(exo_kuroshio))
```

```
## [1] 0
```



得られたオブジェクトのクラスは `mts` であり、base R の `ts` クラスの多変量形式です。各列は別々の外生変数として扱われ、列名は要約や係数表のラベルとして用いられます。

外生変数ありモデルの適用

次に、2つのシミュレーション黒潮変数を `exo_data` として与えたモデルを当てはめます。

```
res_with <- tempssm(  
  temp_data = sst_sim,  
  exo_data = exo_kuroshio,  
  ar_order = 1  
)  
summary(res_with)  
  
## tempssm summary  
## -----  
## Call:  
## tempssm(temp_data = sst_sim, exo_data = exo_kuroshio, ar_order = 1)  
##  
## Model fit:  
##   Likelihood type: marginal  
##   Log-likelihood : -154.38  
##   k                : 7  
##   Diffuse states : 15  
##   Converged      : TRUE  
##  
## Variance parameters:  
##   Observation (H): 0.003184407  
##   State (Q trend): 4.132733e-06  
##   State (Q season): 0.0006818023  
##   State (Q ar): 0.1556755  
##  
## Components of auto-regression:  
##   Order of AR: 1  
##   Coefficient of AR1: 0.6585956  
## Exogenous variable   kuroshio_a distance  
## Estimated coefficient    0.5110124 -0.007070968  
## Lower CI   0.1658023 -0.008467629  
## Upper CI   0.8562225 -0.005674308  
  
resid_with <- get_tempssm_residuals(res_with)  
plot_tempssm_residuals(resid_with)
```

Residuals



```
diag_res_with <- diagnose_residual_ts(resid_with)
print(diag_res_with)
```

```
## # A tibble: 1 x 8
##   lb_stat lb_lag lb_df lb_pvalue kurtosis      n n_missing n_finite
##   <dbl> <int> <int>     <dbl>     <dbl> <int>     <int>     <int>
## 1    6.50    12    12     0.889     3.07   302         80     222
```

残差時系列プロットからは、散漫初期化による散漫成分が解消されるまでの期間に対応して、標準化再帰残差が NA となる期間が 2004 年まで及んでいることが見て取れます。このモデルの残差診断でも、lag 12 までの有意な残差自己相関は認められません。したがって、ここで比較する 2 つのモデルでは、AR(1) は妥当な作業上の仕様と考えられます。

次に、外生変数の推定係数を確認します。

```
exo_coef
```

```
##   Variable Coefficient      lwr      upr
## 1 kuroshio_a 0.511012406 0.165802340 0.856222472
## 2 distance -0.007070968 -0.008467629 -0.005674308
```

係数表は、潜在成分を考慮したうえで、SST と各シミュレーション黒潮変数との推定された関係を要約しています。このモデルでは、kuroshio_a の推定係数は 0.51 °C であり、95% 信頼区間は 0.17 から 0.86 です。kuroshio_a はバイナリ指標なので、この係数は、他のモデル成分と distance を条件づけたうえでの、A 型条件と非 A 型条件の推定 SST 差として解釈することができます。

distance の推定係数は -0.007 °C/単位であり、95% 信頼区間は -0.008 から -0.006 です。これは、潜在成分と kuroshio_a を条件づけたうえで、シミュレーション距離指標の値が大きいくほど SST がわずかに低くなることを意味します。

これらはシミュレーション例に基づく推定値であり、複数の外生変数を持つモデルを当てはめ、係数を確認す

る方法を示すためのものです。黒潮流路に関する新しい科学的証拠として解釈するものではありません。

外生変数を含むモデルで `predict()` を用いる場合、将来時点の外生変数の値が必要です。利用可能な場合は、`exo_data` と同じ変数・同じ列順で `new_exo_data` に与えます。1 時点先の簡易的な可視確認として、`exo_strategy = "last"` を指定すると、最後に観測された外生変数の行を将来値として持ち越す持続性仮定を用います。

```
pred_with_last_exo <- predict(res_with, exo_strategy = "last")
pred_with_last_exo
```

```
##           Mar
## 2023 18.37914
```

推定成分の比較

2 つのモデルの平滑化された点推定値を重ねて表示し、推定された長期トレンドとドリフトを比較します。

```
level_without <- get_level_ts(res_without)
level_with <- get_level_ts(res_with)
drift_without <- get_drift_ts(res_without)
drift_with <- get_drift_ts(res_with)


component_compare <- rbind(
  data.frame(
    time = as.numeric(time(level_without)),
    component = "Level component (°C)",
    model = "Without exogenous variables",
    estimate = as.numeric(level_without)
  ),
  data.frame(
    time = as.numeric(time(level_with)),
    component = "Level component (°C)",
    model = "With Kuroshio variables",
    estimate = as.numeric(level_with)
  ),
  data.frame(
    time = as.numeric(time(drift_without)),
    component = "Drift component (°C/year)",
    model = "Without exogenous variables",
    estimate = as.numeric(drift_without)
  ),
  data.frame(
    time = as.numeric(time(drift_with)),
    component = "Drift component (°C/year)",
    model = "With Kuroshio variables",
    estimate = as.numeric(drift_with)
  )
)

component_compare$component <- factor(
  component_compare$component,
  levels = c("Level component (°C)", "Drift component (°C/year)")
)

plt_component_compare <- ggplot(
  component_compare,
  aes(x = time, y = estimate, color = model)
)
```

```
) +
  geom_line(linewidth = 0.8) +
  facet_wrap(~ component, ncol = 1, scales = "free_y") +
  labs(x = "Time (year)", y = "Estimate", color = "Model") +
  theme_classic()

plot(plt_component_compare)
```



```
mean_drift_year_without <- mean(drift_without, na.rm = TRUE)
mean_drift_year_with <- mean(drift_with, na.rm = TRUE)
```

```
mean_drift_year_without
```

```
## [1] 0.08777084
```

```
mean_drift_year_with
```

```
## [1] 0.04924515
```

レベル成分では、両モデルとも、記録の開始期から 2008 年前後まで低下し、その後に上昇する大局的なパターンを示しています。ただし、外生変数ありモデルは、外生変数なしモデルと比べて、前半の水準を高めに、後半の水準をやや低めに推定しています。

モデル間の違いは、ドリフト成分でより明瞭です。外生変数なしモデルでは、変化率に局所的な揺らぎがみられる一方、シミュレーション黒潮変数を含むモデルでは、負から正への移行がより滑らかに推定されています。このことは、ベースラインモデルのドリフト成分に表れていた短期から中期的な変動の一部が、シミュレーション外生変数によって説明されている可能性を示唆します。

観測期間を通した SST の年あたりの変化率の推定値は、外生変数なしモデルでは 0.0878、外生変数ありモデル

ルでは 0.0492 となりました。

このシミュレーション例は、外部要因を含めることで、推定される長期成分が変化しうること示しています。次節では、この違いが条件付き予測性能にも反映されるかを時系列交差検証で確認します。

時系列交差検証 (tsCV) による条件付き予測性能の評価

時系列交差検証 (tsCV) は、時間順序を保ちながら標本外予測誤差を評価する方法です。モデルを訓練期間に繰り返し当てはめ、その後続の観測値に対する予測性能を評価するため、未来から過去への情報漏洩を避けることができます。

ここでは、シミュレーション黒潮変数を含むモデルと含まないモデルを比較し、外生変数として追加した情報が標本外予測性能にも反映されるかを評価します。

外生変数ありモデルでは、テスト期間のシミュレーション黒潮変数の値を予測ステップに与えています。したがって、この tsCV は、各テスト期間の外生変数値が既知であるという条件下での conditional forecast、または hindcast 的な評価に相当します。

実際の将来予測では、将来の外生変数値は通常未知です。その場合には、将来シナリオを与える、外生変数自体を別モデルで予測する、あるいは最終観測値を持ち越すような簡易仮定を用いる、といった対応が必要になります。したがって、以下の結果は条件付き予測性能の評価として解釈してください。

```
## Generate a list of training and test datasets with their indices
# Procedure for constructing year-based time-series cross-validation folds:
#
# First training data: January 1998-December 2010;
# First test data: January 2011-December 2011
#
# Second training data: January 1999-December 2011;
# Second test data: January 2012-December 2012
# ...
#
# Twelfth training data: January 2009-December 2021;
# Twelfth test data: January 2022-December 2022
#
# These folds are automatically generated by the ts_train_test_split() function.
# The final two observations in 2023 are not used because allow_partial = FALSE
# keeps every test set as a complete 12-month period.

# Generate training and test dataset for model without exogenous variables
folds_without <- ts_train_test_split(
  temp_data = sst_sim,
  exo_data = NULL,
  initial = 156, # 156 monthly observations from Jan 1998 to Dec 2010
  horizon = 12, # forecast 12 monthly observations
  step = 12, # move the fixed-width window in one-year steps
  fixed_window = TRUE,
  allow_partial = FALSE
)

# Generate training and test dataset for model with Kuroshio variables
folds_with <- ts_train_test_split(
  temp_data = sst_sim,
  exo_data = exo_kuroshio,
  initial = 156, # 156 monthly observations from Jan 1998 to Dec 2010
  horizon = 12, # forecast 12 monthly observations
```

```

    step = 12, # move the fixed-width window in one-year steps
    fixed_window = TRUE,
    allow_partial = FALSE
  )

  # Check the first fold
  start(folds_without[[1]]$train_ts)

## [1] 1998    1
end(folds_without[[1]]$train_ts)

## [1] 2010   12
start(folds_without[[1]]$test_ts)

## [1] 2011    1
end(folds_without[[1]]$test_ts)

## [1] 2011   12
# *****
# Executing time-series cross validation

#-----
# Model without exogenous variables

# ts_cv_run() evaluates folds sequentially by default.
cv_without_results <- ts_cv_run(
  folds_without,
  ar_order = 1,
  use_season = TRUE
)

# Optional parallel execution:
# Calling library(future) or library(future.apply) is not required here,
# but these suggested packages must be installed.
# cv_without_results <- ts_cv_run(
#   folds_without,
#   ar_order = 1,
#   use_season = TRUE,
#   parallel = TRUE,
#   workers = 2
# )

# Computing assessment indexes
metrics_without <- lapply(cv_without_results, compute_cv_metrics)

# tidy summary
cv_without_tbl <- ts_cv_collect(cv_without_results, metrics_without) %>%
  mutate(Model="Without")

#-----
# Model with simulated Kuroshio exogenous variables

```

```

cv_with_results <- ts_cv_run(
  folds_with,
  ar_order = 1,
  use_season = TRUE
)

# Optional parallel execution:
# Calling library(future) or library(future.apply) is not required here,
# but these suggested packages must be installed.
# cv_with_results <- ts_cv_run(
#   folds_with,
#   ar_order = 1,
#   use_season = TRUE,
#   parallel = TRUE,
#   workers = 2
# )

# Computing assessment indexes
metrics_with <- lapply(cv_with_results, compute_cv_metrics)

# tidy summary
cv_with_tbl <- ts_cv_collect(cv_with_results, metrics_with) %>%
  mutate(Model="With")

cv_tbl <- bind_rows(cv_without_tbl, cv_with_tbl)

cv_comparison <- compare_ts_cv(
  list(
    Without = cv_without_tbl,
    With = cv_with_tbl
  )
)

cv_comparison %>% knitr::kable()

```

model	n_folds	con- verged_n	converged_rate	mean_MAE	mean_MASE_naive	mean_MASE_seasonal
With- out	12	12	1	0.5375966	0.3137671	0.8001065
With	12	12	1	0.5135379	0.2997563	0.7705862

```

plt_MAE <- ggplot(data=cv_tbl,
  aes(x=Model,y=MAE)) +
  geom_boxplot()

plt_MASE_naive <- ggplot(data=cv_tbl,
  aes(x=Model,y=MASE_naive)) +
  geom_boxplot()

plt_MASE_seasonal <- ggplot(data=cv_tbl,
  aes(x=Model,y=MASE_seasonal)) +


```



```
geom_boxplot()

plt_tsCV <- plt_MAE + plt_MASE_naive + plt_MASE_seasonal +
  patchwork::plot_layout(nrow = 1)

plot(plt_tsCV)
```



3つの精度指標は、予測誤差を異なる観点から要約します。MAE は平均絶対誤差で、応答変数と同じ単位、ここでは $^{\circ}\text{C}$ で表されます。MASE は、訓練データから計算される単純なベンチマークに対する、単位を持たないスケール化誤差です。いずれの指標も、小さいほど予測性能が高いことを意味します。

このチュートリアルでは、MASE_naive は訓練系列の1期差分に基づく非季節 naive ベンチマークを用います。MASE_seasonal は、訓練系列の季節周期だけ離れた差分に基づく seasonal naive ベンチマークを用います。月別データでは、これは12か月差分に対応します。MASE が1未満であれば、平均的には対応する naive ベンチマークよりも良い予測性能を示します。

compare_ts_cv() によって作成された比較表では、各モデルの fold 数、収束率、および平均的な予測誤差指標を確認できます。箱ひげ図からは、検証期間ごとの誤差のばらつきを確認できます。このチュートリアルでは12個の年次テスト期間を用いており、この例題データ内で2つのモデル仕様を比較する実用的な基盤となります。正式なモデル評価では、時系列の長さ、予測期間、予測目的に応じて fold の数と構造を決めてください。

外生変数ありモデルの平均 MAE は約 0.51°C です。月別平均に基づく季節変動幅 (約 9.9°C) と比べると、これは約 5.2% に相当します。したがって、このデータセットにおける主要な季節変動スケールと比べれば、予測誤差は小さく、目的に応じては実用的な精度のモデルと解釈できる可能性があります。

外生変数ありモデルは、外生変数なしモデルに比べて平均 MAE を約 4.5% 低下させました。同様の改善は MASE 指標でも確認されます。ただし、この解釈は、テスト期間のシミュレーション黒潮変数を外生変数として与える条件付き予測の設定に基づくものです。

係数推定、推定成分の比較、tsCV の結果をあわせて確認することで、外生変数ありモデルを多面的に評価できます。ここで用いたデータはシミュレーションデータであるため、黒潮変動に関する新しい科学的結論ではなく、ワークフローの例として解釈してください。同様の流れは、他の環境・気候・生態学的な共変量にも拡張できます。その際には、モデル診断、予測性能、将来の外生変数に関する仮定を明示的に確認することが重要です。

ユーザーのオリジナルデータの使用について

CSV 形式

月別温度時系列の CSV ファイルでは、Year、Month、Temp という列を用意します。- Year - Month - Temp 例:

```
Year,Month,Temp
2010,8,13.6
2010,9,6.8
2010,10,NA
2010,11,-1.4
...
```

- 欠測した温度値には NA を使用し、対応する Year と Month の行は必ず保持してください。
- CSV ファイルはカンマ区切りで、UTF-8 エンコーディングとしてください。

CSV から ts オブジェクトへの変換

本パッケージに同梱するサンプル CSV ファイルは inst/extdata にあります。このサンプルデータセットには、北海道赤岳 (1,840 m) における月別気温観測値が含まれています。オリジナルデータは環境省のモニタリングサイト 1000 (KOZ01.zip、<https://www.biodic.go.jp/moni1000/findings/data/index.html>) から入手可能です。

```
path <- system.file("extdata", "example_monthly_temp.csv", package = "tempssm")
akadake_temp <- tempssm::read_monthly_temp_ts(path)
head(akadake_temp)
```

```
##           Jan Feb Mar Apr May Jun Jul   Aug   Sep   Oct   Nov   Dec
## 2010                                13.6   6.8   0.2  -6.8 -12.5
## 2011 -18.8
```

read_monthly_temp_ts() 関数は、このような CSV ファイルを読み込み、tempssm() で利用できる R の ts オブジェクトへ変換します。より細かな制御が必要な場合は、手動で ts オブジェクトを作成することもできます。詳細は R 公式の stats::ts ドキュメントを参照してください：<https://search.r-project.org/R/refman/s/stats/html/ts.html>。

データがすでに R の ts オブジェクトとして保存されている場合は、そのまま tempssm() に渡すことができます。

参考文献

tempssm に実装されている統計モデリングの枠組みは、馬場ら (2024) に記述された方法論に基づいており、付随する補足資料およびコードリポジトリが本パッケージ開発の初期ソースとなっています。

馬場真哉, 石井 洋, 芳山 拓. (2024). 線形ガウス状態空間モデルを用いた神奈川県城ヶ島地先における海水温トレンドの推定. 水産海洋研究, 88(3), 190–199. https://doi.org/10.34423/jsfo.88.3_190

馬場真哉. (2024). 線形ガウス状態空間モデルを用いた海水温トレンド推定のための補足コードおよびテストデータ. GitHub リポジトリ: <https://github.com/logics-of-blue/sea-temperature-trend-jogashima>

Helske, J. (2017). KFAS: KFAS: Exponential family state space models in R. *Journal of Statistical Software*, 78(10), 1–39. <https://doi.org/10.18637/jss.v078.i10>

付録: ユーティリティ関数

データ準備と探索的解析を支援するために、以下のユーティリティ関数が提供されています。

1. read_monthly_temp_ts()

`read_monthly_temp_ts()` 関数は、CSV ファイルに保存された月別温度データを R の `ts` オブジェクトへ変換します。単純で一貫したデータ形式を課すことで、外部で準備された時系列データを `tempssm` に取り込みやすくすることを目的としています。

例

月別温度データでは、ヘッダー行をもつ CSV ファイルを準備します。デフォルトでは、列名は `Year`、`Month`、`Temp` である必要があります。ここで `Temp` は観測された温度値を表します。

```
Year,Month,Temp
2001,1,10.4
2001,2,8.2
2001,3,NA
2001,4,13.6
2001,5,16.1
...
```

- 欠測した温度値には `NA` を使用し、対応する `Year` と `Month` の行は必ず保持してください。
- CSV ファイルはカンマ区切りで、UTF-8 エンコーディングとしてください。

次の例では、パッケージに含まれるサンプル CSV ファイルを使用します。このファイルには、北海道赤岳における月別気温観測値が含まれています。

```
path <- system.file("extdata", "example_monthly_temp.csv", package = "tempssm")

# Read the CSV file and convert it to a monthly ts object
temp_ts <- read_monthly_temp_ts(path)
head(temp_ts)
```

```
##           Jan Feb Mar Apr May Jun Jul   Aug   Sep   Oct   Nov   Dec
## 2010                                13.6   6.8   0.2  -6.8 -12.5
## 2011 -18.8
```

2. convert_monthly_df_to_ts()

`convert_monthly_df_to_ts()` 関数は、月別温度データを含むデータフレームを R の `ts` オブジェクトへ変換します。この関数は、温度データをまずデータフレームとして読み込みまたは準備し、その後に時系列解析で使用するワークフローを支援するために設計されています。

入力データフレームには、少なくとも日付列 (`Date`) と温度列 (`Temp`) の 2 列が含まれていることが想定されています。なお日付列 (`Date`) について、月別の温度の集計値と対応させるために、日は任意の日数 (たとえば 1 日) を与えてください。

例

```
# Create a data frame of monthly temperature data
df <- data.frame(
```

```

Date = as.Date(c(
  "2001-01-01",
  "2001-02-01",
  "2001-03-01",
  "2001-04-01",
  "2001-05-01")
),
Temp = c(10.4, 8.2, NA, 13.6, 16.1)
)

# Convert to a monthly ts object
temp_ts <- convert_monthly_df_to_ts(df)
head(temp_ts)

```

```

##           Jan  Feb  Mar  Apr  May
## 2001 10.4   8.2   NA  13.6 16.1

```

3. get_jma_sst_ts()

get_jma_sst_ts() 関数は、気象庁（JMA）が提供する日本沿岸域の日平均海面水温（SST）データをダウンロードします。日別値を月平均へ集計し、得られた時系列を ts クラスのオブジェクトとして返します。

例

次の例では、茨城県南部沿岸域の SST データをダウンロードする方法を示します。

引数 sea_area_id は、JMA によって定義された海域の数値 ID を指定します。例えば、138 は茨城県南部沖の沿岸域に対応します。利用可能な海域 ID と対応す地域の一覧は、JMA により以下で提供されています。

https://www.data.jma.go.jp/kaiyou/data/db/kaikyo/series/engan/eg_areano.html

```

sst_138_ts <- get_jma_sst_ts(sea_area_id = 138)
head(sst_138_ts)

```

```

##           Jan      Feb      Mar      Apr      May      Jun
## 1982 15.04419 14.22500 13.63903 15.31933 17.52258 19.52300

```

4. compute_temp_anomaly()

compute_temp_anomaly() 関数は、R の ts オブジェクトとして与えられた時系列から偏差を計算します。偏差は、各観測値から対応する周期単位（たとえば月）の長期平均を差し引くことで計算され、周期の影響を取り除いた年変動パターンの確認などに用いられます。

偏差を計算するための基準期間は、関数引数で指定できます。デフォルトでは、利用可能な時系列全体を用いて平年値が計算されます（?compute_temp_anomaly を参照）。


この変換は、典型的な季節条件からのずれに注目する探索的解析やモデリング用途で有用です。

例

```

# Generate temperature anomalies
data(sst_niigata)
sst_niigata_anomaly <- compute_temp_anomaly(sst_niigata)
plt_sst_niigata_anomaly <- forecast::autoplot(sst_niigata_anomaly) +
  labs(y = expression(Temp.~(degree*C)),
       x = "Time (year)")
plot(plt_sst_niigata_anomaly)

```



5. compute_monthly_climatology()

`compute_monthly_climatology()` 関数は、`ts` オブジェクトから、各季節値を 年をまたいで平均することにより、気候値 (climatology: 気候学的な平均季節周期) を計算します。主として、温度時系列における季節構造の探索的解析と可視化を目的としています。

例

```
data(sst_niigata)
monthly_seasonal_cycle_sst_niigata <- compute_monthly_climatology(sst_niigata)
summary(monthly_seasonal_cycle_sst_niigata)
```

```
##      Month      Temperature
## Min.   : 1.00   Min.   : 9.365
## 1st Qu.: 3.75   1st Qu.:11.169
## Median : 6.50   Median :16.318
## Mean   : 6.50   Mean   :17.036
## 3rd Qu.: 9.25   3rd Qu.:22.294
## Max.   :12.00   Max.   :26.873
```

```
plt_monthly_seasonal_cycle_sst_niigata <- ggplot(
  data = monthly_seasonal_cycle_sst_niigata,
  aes(x = Month, y = Temperature)
) +
  geom_point(size = 2) +
  geom_line(linetype = "dashed") +
  labs(
    title = "Monthly seasonal cycle of temperature",
    x = "Month",
```

```
y = expression(Temp.~(degree*C))  
) +  
scale_x_continuous(  
  breaks = 1:12,  
  labels = sprintf("%02d", 1:12)  
) +  
theme_classic()
```

```
plot(plt_monthly_seasonal_cycle_sst_niigata)
```

